Lab #12 – Save Chernobyl – Entregable 2: Criterios hipotéticos de escalabilidad

Arquitectura de Software 2026-II · Prof. Carlos Balbuena · TEAM: Maquera - Barzola · INTEGRANTES: Luis Maquera, Johar Barzola

Son hipotéticos porque aún no hay data: se confirman con logs, monitoring, dashboards y performance testing (S10). Regla: "Scale your architecture only when needed, not before" (S11 p8).

1. Nuestra load (lo que estresa al sistema)

La load no son los operadores, son las mediciones (S5: "define cuál es tu LOAD").

Cálculo	Valor
1 sensor: 1 envío cada 0.05 s	20 mediciones/s
1 reactor: hasta 100 sensores	2 000 mediciones/s
3 reactores	**6 000 mediciones/s**
Por día (× 86 400 s)	≈ 518 millones de mediciones
Supuesto: ~100 bytes por registro	≈ 52 GB/día de trazabilidad

Por eso la trazabilidad viaja por una cola asíncrona y se guarda en tablas con columna de latencia, sin impactar al control: "si el logging se cae, la aplicación debe continuar" (S10 p25-p28).

2. Qué medimos en el dashboard

Las cuatro métricas de escalabilidad del curso (S10 p41): tráfico (mediciones/s y comandos/s), availability = 2xx/(2xx+5xx), reliability = 2xx/(2xx+4xx+5xx) (S10 p26) y latencia P95/P99 (nunca el promedio, S5).

3. CUÁNDO escalar: umbrales Good / OK / Bad (formato fitness function, S7)

FF	Dimensión e indicador	Good	OK	Bad	Cómo se mide
FF1	Latencia P99 medición → decisión local → comando a refrigeración (critical path)	≤ 50 ms	≤ 100 ms	> 100 ms	monitoring por reactor; test de latencia en cada PR, Bad bloquea el merge
FF2	Latencia P99 Controller → Main Controller (decisión global)	≤ 200 ms	≤ 500 ms	> 1 s	monitoring + load testing
FF3	Availability del control por reactor	≥ 99.9 %	≥ 99.5 %	< 99.5 %	tabla de transacciones (2xx/5xx)
FF4	Reliability de comandos (ON/OFF con ack correcto)	≥ 99.9 %	≥ 99 %	< 99 %	tabla de transacciones (2xx/4xx/5xx)
FF5	Tráfico sostenido vs capacidad medida con load testing	< 50 %	50-70 %	> 70 % por 10 min	dashboard de tráfico
FF6	Atraso (lag) de la cola de eventos de trazabilidad	< 1 s	< 5 s	> 30 s	monitoring de la cola

Regla de decisión (S10 p55-p56 y escenarios p80-p83): - Tráfico sube → availability baja → latencia sube ⇒ **es hora de escalar** (escenario 2: crecimiento sostenido). - Pico transitorio que ya bajó (escenario 3) ⇒ no se escala; lo absorbe la cola. - Caída súbita con availability crítica (escenario 4) ⇒ no es escalabilidad, es un incidente: RCA.

4. QUÉ escalar: el bottleneck, "no con intuición, con métricas" (S11 p61)

Se busca el P95/P99 más alto, el recurso saturado (CPU, memoria, I/O, red) y las colas de espera, usando performance testing (S10 p62-p69): load (fijar umbrales), stress (validar el LB), spike (picos de alarmas), volume (hasta dónde aguanta la Log DB), endurance (memory leaks de un controller 24/7).

Candidatos hipotéticos: Main Controller (recibe las 6 000 mediciones/s), Log DB (escrituras), panel de operadores (lecturas), red Controller ↔ Main.

5. CÓMO escalar: patrón mínimo necesario (S11 p62)

Tipo de bottleneck	Patrón (en orden)	En Save Chernobyl
Cómputo (CPU alta en Main Controller)	Escala horizontal → más instancias + LB	Main Controller stateless replicado detrás del LB con /health
Datos (lecturas del panel lentas)	Cache-aside → Read Replicas → Sharding	últimas lecturas en cache con TTL corto; reportes en Read Replica; sharding natural por reactor
I/O (escrituras de logs lentas)	Queue asíncrona → Write Replica	la cola de eventos ya está; Write Replica si las escrituras superan el 30 %
Red (latencia Controller ↔ Main)	Sidecar (mismo host)	logging y monitoring como side-car del controller
Concurrencia (locks en Log DB)	Read Replicas → revisar índices	lecturas del panel fuera de la Master; índices por reactor y fecha

- Scale out (horizontal) para lo stateless; scale up (vertical) solo en la BD primaria, que tiene límite físico (S3).
- **Nuevo reactor = nuevo shard**: se agrega un controller local y su partición de trazabilidad sin tocar los demás reactores.
- Trade-off: "más instancias = más costo, mismo P99" si el bottleneck no es cómputo (S11 p63). Primero medir, después escalar.